

Construction et évaluation

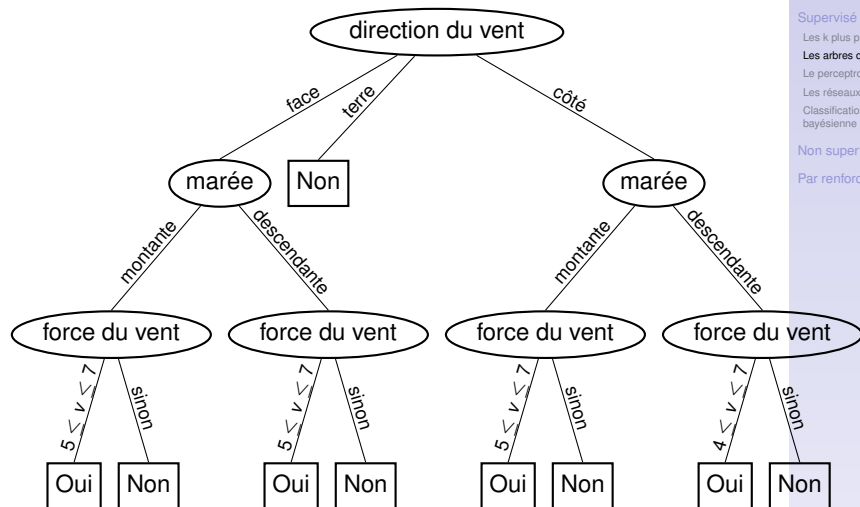
- ▶ Quels attributs sélectionner pour construire l'arbre ?
- ▶ Comment évaluer un arbre ? A priori on souhaite minimiser le nombre de tests (en moyenne) pour classifier un exemple (il existe une borne max sur le nombre d'attributs).

Un premier exemple

- ▶ La force du vent : attribut numérique $\{1 \dots 12\}$.
- ▶ La direction du vent : attribut nominal {face, terre, côté}
- ▶ La marée : attribut nominal {montante, descendante}

- ▶ Décision à prendre : puis-je faire de la planche à voile ?

Les arbres de décisions



Comment construire un arbre de décisions

- ▶ Parcours exhaustif des arbres impossible.
- ▶ Exponentiel en fonction de
 - ▶ nombre d'attributs d .
 - ▶ nombre moyen de valeurs par attribut : v .
 - ▶ $\sum_{i=0}^{d-1} (d-i)^{v^i}$
 - ▶ Par exemple, avec 6 attributs et $v = 2$ on a déjà 72385.

Algorithm 1 Construction récursive d'un arbre de décision

```
1: Procédure : construireArbre( $X$ )  
2: if Tous les points de  $X$  appartiennent à la même classe  
   then  
3:   Créer une feuille portant le nom de cette classe  
4: else  
5:   Choisir le meilleur attribut pour créer un noeud  
6:   Le test associé à ce noeud sépare  $X$  en  $X_g$  et  $X_d$ .  
7:   construireArbre( $X_g$ )  
8:   construireArbre( $X_d$ )  
9: end if
```

Quelques définitions

- ▶ Un exemple n_i est décrit par :
 - ▶ d attributs.
 - ▶ u une classe $\in U = \{u_1, \dots, u_c\}$
- ▶ Soient n points de l'échantillon d'apprentissage, répartis en U classes u_j comportant chacune n_j exemples.
- ▶ Soit a un attribut binaire quelconque.
- ▶ a partage chaque n_j en deux sous parties, comportant :
 - ▶ l_j points pour $a = \text{vrai}$.
 - ▶ r_j points pour $a = \text{faux}$.

On peut alors déduire que

- ▶ l_j/n est une estimation de $P(a = \text{vrai}, u = u_j)$.
- ▶ r_j/n est une estimation de $P(a = \text{faux}, u = u_j)$.
- ▶ l/n est une estimation de $P(a = \text{vrai})$.
- ▶ r/n est une estimation de $P(a = \text{faux})$.
- ▶ n_j/n est une estimation de $P(u = u_j)$.

Théorie de l'information

- ▶ Information mutuelle (entropie croisée).
- ▶ Permet de mesurer l'homogénéité entre deux distributions de probabilités.
- ▶ Soient u et a deux variables, avec D_u et D_a leurs ensembles finis de valeurs possibles.
- ▶ L'entropie croisée est donnée par :

$$\mathbb{I}(u, a) = - \sum_{i,j \in D_u \times D_a} p(i, j) \log_2 \frac{p(i, j)}{p(i)p(j)}$$

Quelques propriétés

- ▶ $\mathcal{I}(u, a)$ possède un minimum (0) quand $p(i, j) = p(i)p(j)$: lorsque les deux distributions sont indépendantes.
- ▶ $\mathcal{I}(u, a)$ est maximale lorsque les deux distributions sont complètement corrélées.

Quelques propriétés

- ▶ Une variable aléatoire w possède une entropie $H(u)$ défini par :

$$H(u) = - \sum_{i \in D_u} p(i) \log_2(p(i))$$

- ▶ L'entropie de w conditionnée par a est définie par :

$$H(u|a) = - \sum_{i,j \in D_u \times D_a} p(i,j) \log_2(p(i|j))$$

- ▶ Or d'après la théorie de l'information, on a :

$$\mathbb{I}(u, a) = H(u) - H(u|a)$$

$$\blacktriangleright \hat{I}(u, a) = - \sum_{j=1}^Y \frac{l_j}{n} \log_2 \frac{l_j/n}{(l/n)(n_j/n)} + \frac{r_j}{n} \log_2 \frac{r_j/n}{(r/n)(n_j/n)}$$

$$\blacktriangleright \hat{H}(u|a) = - \sum_{j=1}^Y \frac{l}{n} \frac{l_j}{l} \log_2 \frac{l_j}{l} + \frac{r}{n} \frac{r_j}{r} \log_2 \frac{r_j}{r}$$

Quelques propriétés

- ▶ On peut donc estimer les probabilités :

$$\hat{H}(u|a) = \frac{l}{n} J(a = \text{vrai}) + \frac{r}{n} J(a = \text{faux})$$

avec

$$J(a = \text{vrai}) = - \sum_{j=1}^U \frac{l_j}{l} \log_2 \frac{l_j}{l}$$

$$J(a = \text{faux}) = - \sum_{j=1}^U \frac{r_j}{r} \log_2 \frac{r_j}{r}$$

Choix de l'attribut

- ▶ On veut choisir l'attribut qui possède la plus grande corrélation avec la répartition des classes.
- ▶ On va donc chercher à minimiser l'entropie :

$$i^* = \arg \min_{i=1, \dots, d} (\hat{H}(u|a_i))$$

Problème

Le problème consiste à prédire si un enfant peut aller jouer avec son voisin.

Base d'exemples

Les décisions prises sur les 8 derniers jours étant donnés 4 attributs binaires et 1 classe.

Échantillon d'apprentissage

	Devoirs finis ?	Bonne humeur de la mère ?	Beau temps ?	Gouter pris ?	Décision
1	vrai	faux	vrai	faux	oui
2	faux	vrai	faux	vrai	oui
3	vrai	vrai	vrai	faux	oui
4	vrai	faux	vrai	vrai	oui
5	faux	vrai	vrai	vrai	non
6	faux	vrai	faux	faux	non
7	vrai	faux	faux	vrai	non
8	vrai	vrai	faux	faux	non

Simplifions les notations : (DF, BH, BT, GP).

Un exemple de construction

	Devoirs finis ?	Bonne humeur de la mère ?	Beau temps ?	Gouter pris ?	Décision
1	vrai	faux	vrai	faux	oui
2	faux	vrai	faux	vrai	oui
3	vrai	vrai	vrai	faux	oui
4	vrai	faux	vrai	vrai	oui
5	faux	vrai	vrai	vrai	non
6	faux	vrai	faux	faux	non
7	vrai	faux	faux	vrai	non
8	vrai	vrai	faux	faux	non

Calcul de $H(u = \text{oui} | DF)$

$$H(\text{oui} | DF) = \frac{5}{8} J(DF = \text{vrai}) + \frac{3}{8} J(DF = \text{faux})$$

$$J(DF = \text{vrai}) = -\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5}$$

$$J(DF = \text{faux}) = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{3}$$

On obtient

- ▶ $H(\text{oui}|DF) \approx 0.9$
- ▶ $H(\text{oui}|BT) \approx 0.8$
- ▶ $H(\text{oui}|BH) \approx 0.9$
- ▶ $H(\text{oui}|GP) \approx 1$

On choisit donc pour racine l'attribut "Est ce qu'il fait beau ?"

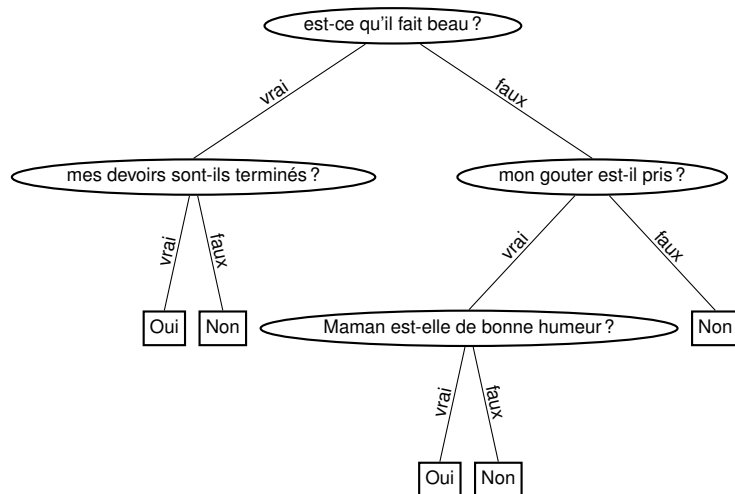
Table pour la valeur vrai

	Devoirs finis ?	Bonne humeur de la mère ?	Gouter pris ?	Décision
1	vrai	faux	faux	oui
3	vrai	vrai	faux	oui
4	vrai	faux	vrai	oui
5	faux	vrai	vrai	non

Table pour la valeur faux

	Devoirs finis ?	Bonne humeur de la mère ?	Gouter pris ?	Décision
2	faux	vrai	vrai	oui
6	faux	vrai	faux	non
7	vrai	faux	vrai	non
8	vrai	vrai	faux	non

Un exemple de construction



Pourquoi élaguer ?

- ▶ L'arbre précédemment construit est dit T_{max} : chaque feuille est pure.
- ▶ Il y a un risque de sous estimer la probabilité d'erreur.

Le pré-élagage

- ▶ On cesse de diviser un noeud lorsque la pureté des points est suffisantes (inférieure à un certain seuil).
- ▶ Utilisation de critères locaux (à une feuille) : on peut manquer un très bon développement.
- ▶ Donc, utilisation du post-élagage.

Le post-élagage

- ▶ Élaguer l'arbre lorsqu'il est parfaitement développé.
- ▶ Utiliser un ensemble indépendant de l'ensemble d'apprentissage (ensemble de validation).
- ▶ Mesurer l'erreur commise sur cet ensemble.

Méthode

- ▶ En partant des feuilles, construire une séquence d'arbres $\{T_{max}, T_1, T_2, \dots, T_n\}$ (T_n est l'arbre constitué d'une seule feuille).
- ▶ A chaque étape un noeud est transformé en feuille.
- ▶ L'idée est de comparer le coût de l'arbre élagué et de l'arbre non élagué. On s'arrête si le coût du premier est supérieur.

Estimation du coût

Choisir le noeud v qui minimise :

$$\hat{w}(T_k, v) = \frac{MC_{ela}(v, k) - MC(v, k)}{n_k \cdot (nt(v, k) - 1)}$$

- ▶ $MC_{ela}(v, k)$: nombre d'exemples de l'ensemble d'apprentissage mal classés **par** le noeud v de T_k dans l'arbre élagué à v .
- ▶ $MC(v, k)$: nombre d'exemples de l'ensemble d'apprentissage mal classés **sous** le noeud v de T_k dans l'arbre **non** élagué à v .
- ▶ n_k : nombre de feuilles de T_k .
- ▶ $nt(v, k)$: nombre de feuilles du sous-arbre de T_k situé sous le noeud v .

On cherche le meilleur compromis entre le taux d'erreur apparent et la taille.

Intro

Supervisé

Les k plus proches voisins

Les arbres de décisions

Le perceptron

Les réseaux de neurones

Classification naïve
bayésienne


Non supervisé

Par renforcement


Algorithm 2 Algorithme d'élagage

```
1: Procédure :  $\text{elaguer}(T_{\max})$ 
2:  $k \leftarrow 0$ 
3:  $T_k \leftarrow T_{\max}$ 
4: while  $\text{nbNoeud}(T_k) > 1$  do
5:   for chaque noeud  $v$  de  $T_k$  do
6:     calculer  $\hat{w}(T_k, v)$  sur l'ensemble d'apprentissage
7:   end for
8:   Choisir le noeud  $v_m$  pour lequel  $\hat{w}$  est minimum
9:    $T_{k+1}$  se déduit de  $T_k$  en y remplaçant  $v_m$  par une feuille
10:   $k \leftarrow k + 1$ 
11: end while
```

Un exemple d'élagage




Un exemple d'élagage



Un exemple d'élagage

Calculer $\hat{w}(T_{max}, v_1)$, $\hat{w}(T_{max}, v_2)$, $\hat{w}(T_{max}, v_3)$,
 $\hat{w}(T_{max}, v_4)$



Calcul des valeurs sur T_{max}

$$\blacktriangleright \hat{w}(T_{max}, v_1) = \frac{MC_{ela}(v_1, k) - MC(v_1, k)}{n(k) \cdot (nt(v_1, k) - 1)} = \frac{9 - 0}{5(5 - 1)} = \frac{9}{20}$$

$$\blacktriangleright \hat{w}(T_{max}, v_2) = \frac{1 - 0}{5(3 - 1)} = \frac{1}{10}$$

$$\blacktriangleright \hat{w}(T_{max}, v_3) = \frac{2 - 0}{5(2 - 1)} = \frac{2}{5}$$

$$\blacktriangleright \hat{w}(T_{max}, v_4) = \frac{1 - 0}{5(2 - 1)} = \frac{1}{5}$$

Calcul des valeurs sur T_{max}

$$\blacktriangleright \hat{w}(T_{max}, v_1) = \frac{MC_{ela}(v_1, k) - MC(v_1, k)}{n(k).(nt(v_1, k) - 1)} = \frac{9 - 0}{5(5 - 1)} = \frac{9}{20}$$


$$\blacktriangleright \hat{w}(T_{max}, v_2) = \frac{1 - 0}{5(3 - 1)} = \frac{1}{10}$$

$$\blacktriangleright \hat{w}(T_{max}, v_3) = \frac{2 - 0}{5(2 - 1)} = \frac{2}{5}$$

$$\blacktriangleright \hat{w}(T_{max}, v_4) = \frac{1 - 0}{5(2 - 1)} = \frac{1}{5}$$

Un exemple d'élagage

On obtient T_1



Intro

Supervisé

Les k plus proches voisins

Les arbres de décisions

Le perceptron

Les réseaux de neurones

Classification naïve
bayésienne

Non supervisé

Par renforcement

Calcul des valeurs sur T_1

$$\blacktriangleright \hat{w}(T_1, v_1) = \frac{9 - 1}{3(3 - 1)} = \frac{4}{3}$$

$$\blacktriangleright \hat{w}(T_1, v_3) = \frac{2 - 1}{3(2 - 1)} = \frac{1}{3}$$


Calcul des valeurs sur T_1

$$\blacktriangleright \hat{w}(T_1, v_1) = \frac{9 - 1}{3(3 - 1)} = \frac{4}{3}$$

$$\blacktriangleright \hat{w}(T_1, v_3) = \frac{2 - 1}{3(2 - 1)} = \frac{1}{3}$$

Un exemple d'élagage


On obtient T_2



Choix de l'arbre

- ▶ Le choix de l'arbre se fera sur un ensemble de validation parmi T_{max} , T_1 et T_2 .
- ▶ L'arbre qui aura la meilleure estimation du taux d'erreur de classification sera choisi.

Par exemple, sur cet ensemble de validation



► Erreur T_{max} : $\frac{3}{16}$

► Erreur T_1 : $\frac{1}{16}$

► Erreur T_2 : $\frac{2}{16}$

Intro

Supervisé

Les k plus proches voisins

Les arbres de décisions

Le perceptron

Les réseaux de neurones

Classification naïve

bayésienne

Non supervisé

Par renforcement